

① Sistem mimarisinin genel özeti ve diyagramlar

Gözcü — Video Analiz ve Karar Destek Sistemi

Gözcü · Takım FERASET (team37) · Muğla Sıtkı Koçman Üniversitesi

TEKNOFEST 2026 Yapay Zekâ Dil Ajanları Yarışması — 3. Senaryo: Video Analiz ve Karar Destek Sistemi

Bu bölüm şartname §6'nın "sistem mimarisinin genel özeti ve diyagramı" kalemidir. Anlatılan mimari **kodda çalışan mimaridir**; her kutunun altında onu uygulayan dosya adı yazılıdır ve iddia edilen her sayının kaynağı gösterilmiştir.

İçindekiler

1. Bir cümlede

2. Katman diyagramı — uçtan uca akış

3. Ajan topolojisi ve model kademeleri

Kademe tablosu — her karar yeten en ucuz modele düşer

4. Pencere karar akışı — mimarinin çekirdeği

5. Kritik an — sekans diyagramı

Neden bu sıra puan getiriyor

6. Devir protokolü — açıklanabilirliğin omurgası

7. Veri modeli — SQLite tek dosya

8. Epizodik hafıza

9. Çıktı sözleşmesi

10. Hata ve kesinti mimarisi

11. Operatör konsolu

12. Yerellik ve bağımsızlık

13. Kod haritası

14. Ölçülmüş rakamlar

15. Bilinen sınırlar

16. Şartname eşleştirmesi

Kaynaklar


1. Bir cümlede

Sistem izlerken karar verir — izledikten sonra özetlemez.

Bu, mimarinin tamamını belirleyen tercihtir. Yüklenen bir videoyu baştan sona işleyip sonunda rapor yazan bir sistem bir **özetleyicidir**; içinde karar anı yoktur. Gözcü videonun kendi saatinde ilerler ve **kritik ana geldiğinde orada durur**: riski biçer, vardiya kayıtlarını ve ekipman geçmişini sorgular, operatöre seslenir, aksiyon önerir ve saha sistemini arar. **Video henüz bitmemiştir**. Kapanıştaki JSON ve kök neden raporu bu döngünün *sonucudur*, yerine geçen şey değil.

Bunun kod tarafındaki karşılığı tek bir satırdır — `DecisionLoop.run()` bir **generator**'dür (`gozcu/loop.py:733`): yükseltme anında `yield` eder, çağıran taraf operatörle konuşur, `next()` döngüyü kaldığı yerden sürdürür. Duraklama bir arayüz numarası değil, akışın kendisidir.


2. Katman diyagramı — uçtan uca akış



Modellere erişim ①'de **hiç yoktur**: algı katmanı ağa çıkmaz. ②–⑥ arasındaki her model çağrısı tek bir kapıdan, kademeli gateway istemcisinden geçer (`gozcu/gateway.py`).

3. Ajan topolojisi ve model kademeleri

Topoloji **süpervizör + uzman alt-ajanlar**'dır. Tek bir ReAct ajanı ve dört bağımsız ajan seçenekleri elenmiştir; belirleyici gerekçe şudur: puanın **%20'si operatör diyalogudur** ve bu topolojide diyalog ajanı zincirin sonundaki bir tüketici değil, sistemin merkezidir.



— döngü tarafı (operatörle konuşmayan, videoyu işleyen ajanlar) —

YÖNLENDİRİCİ →	YORUMLAYICI →	SENTEZLEYİCİ →	(kapanışta) RİSK ANALİSTİ
agents/router	agents/interpreter	agents/synthesizer	
kademe: router	kademe: vlm	kademe: fast	
GÖRÜNTÜ GÖRMEZ	sinial özet	pencere+yorum → Epizot	
okur	okur	(başlangıç/gelişim/sonuç)	

DENETİM (guard) – operatöre giden metni ve teslim paketini süzer;
gozcu/guard.py · kademe: guard · hiçbir koşulda teslimi ENGELLEMEZ

Kademe tablosu — her karar yeten en ucuz modele düşer


Katman	Kademe	İşi	Sıklık
Algı	yere l (YOLOE + ByteTrack)	Tespit, kimlik, sinyal, hareket enerjisi	Her kare
Yönlendirici	router	"Burada dikkat gerektiren bir şey var mı, kime gider?"	Pencere başına ≤1
Yorumlayıcı	v1m	Tetiklenen 10 sn'lik klibi okur, ciddiyet biçer	Yalnız tetikte
Sentezleyici	fast	Gözlem + yorum → Epizot (fazlar, Türkçe özet, ön risk)	Epizot başına
Hafıza	embed (bge-m3, 1024)	Epizot arşivinde anlamsal arama	Sorgu başına
Nöbetçi / Risk / Raportör	main	Diyalog, derin risk, kök neden	Düşük
Denetim	guard	Operatöre giden metni süzer	Çıktı başına

Model kimlikleri yalnızca `gozcu/config.py` 'da yaşar. Başka hiçbir dosyada model adı yazmaz; organizasyon roster'ı değiştirirse değişen tek dosya budur.

Ölçülen gecikmeler (26 Ağustos canlı koşu, `config.py` 'deki kayıt): **router** 0,3–1,8 sn · **fast** 0,9–1,3 sn · **main** 0,8–2,6 sn · **guard** 0,1 sn · **v1m** 7,0–8,7 sn. Uzun olan yalnız görü kademesidir — mimarinin bütün maliyet tasarrufu o çağrıyı **nereye harcayacağını seçmekten** gelir (§4).

4. Pencere karar akışı — mimarının çekirdeği

Kare başına yönlendirme 10 dakikalık bir videoda ~600 model çağırısı ederdi. Sistem karelere değil **10 saniyelik pencerelere** bakar (~60 çağrı) ve pencere başına **en fazla bir görü çağırısı** yapar. Akış:



Bu akışın üç tasarım kararı, üç ayrı ölçülmüş arızanın onarımıdır:


(a) Taban bir alarm kuralı değil, bir "ne zaman soralım" kuralıdır. Hareket sensörü hiçbir alarm sistemini kural tabanlı yapmaz — *neyin önemli olduğuna* model karar verir, taban yalnızca *ne zaman sorulacağını* belirler. Şartnamenin "*statik, yalnızca kural tabanlı çözümler düşük puanlanacaktır*" maddesinin karşılığı budur.

(b) Pahalı bakış, sayaçla değil kanıtla nişanlanır. Görü bütçesi `ceil(pencere_sayısı / 6)` kadardır ve koşunun **bütün** pencereleri arasından **en yüksek kare-farkı enerjisine** sahip olanlara dağıtılır. Bu triyaj yerel ve neredeyse bedavadır: 896 px karelerde **1,9 ms/kare**, 23 karelik bir klipte 44 ms — aynı klipteki tek bir görü çağrısı **3.493 ms** sürüyor, yani triyajın tamamı o çağrının **%1,3'ü** kadar. Ölçümün kaydı `gozcu/loop.py` 'nin modül başındaki notta.

(c) Bu numaranın sınırı açıkça yazılıdır. Top-K sıralama videonun tamamının önceden bilinmesine dayanır. Gerçek bir canlı yayında böyle bir liste yoktur; orada kayan bir eşik ya da rezervuar örnekleme gerektirdi. **Bu tasarım genelleşmiyor ve genelleşiyormuş gibi anlatılmıyor.**

5. Kritik an — sekans diyagramı

Aşağıdaki dizi demo senaryosunun çekirdeğidir ve aynı zamanda kabul testidir (`tests/test_dialog_senaryo.py`). Soldan sağa zaman akar; **hepsi video bitmeden önce** olur.



Diyagramdaki her ok **aksiyon defterine** (`action` tablosu) ve **devir defterine** (`handoff` tablosu) tipli bir kayıt olarak düşer. Hiçbir şey ajan sınırını serbest metin olarak geçmez.

Neden bu sıra puan getiriyor

Diyagramdaki an	Şartname kalemi
Sorulmadan haber verme	Otonomi — "inisiyatif alma"
Vardiya sorgusunun konuşmadan önce yapılması	Mimari — "dinamik araç seçimi"
"Bu açıdan göremiyorum" — uydurmak yerine sormak	Otonomi — "doğru soruları sorma"
Operatör düzeltmesinin rapora kadar yayılması	Mimari — "bağlam yönetimi"
Video bitmeden saha sisteminin aranması	Fonksiyonellik — uçtan uca senaryo
Hat durdurmanın onay istemesi	Mimari — insan döngüde

6. Devir protokolü — açıklanabilirliğin omurgası

Hiçbir şey ajan sınırını serbest metin olarak geçmez. Her devir depoya tipli bir kayıt olarak yazılır

(gozcu/models.py::Handoff):

```
Handoff {
  ts          : 40.0          ← videonun kaçınıcı saniyesi
  source_agent : "router"      ← perception | router | interpreter |
  target_agent : "interpreter" ← synthesizer | risk_analyst |
  reason       : "hız eşiği aşıldı..."  supervisor | reporter
  confidence   : 0.90
  payload_ref  : "window@40.0"
}
```


Üç kazancı vardır:

1. **Puanlanan kalemin kanıtı.** Şartname §7 "*çok adımlı karar zincirleri*"ni ve "*bağlam yönetimi*"ni doğrudan puanlıyor; zincir ekranda okunuyor.
2. **Her sınırda bir test noktası.** Ajanlar birbirini mock'layarak sınanabiliyor.
3. **Açıklanabilirlik.** Şartname "*sistem çıktıları mümkün olduğunca açıklanabilir olmalıdır*" diyor; cevabı bir slayttaki iddia değil, ekranda izlenebilen bir karar zinciri.

Devrin kaynağı **dürüstçe** yazılır: yönlendiriciye hiç uğramamış bir zorunlu örnek `source_agent="perception"` ile ve `[periyodik]` önekiyle deftere düşer — böylece ölçüm katmanı, model kararlarını döngünün kendi kurallarından ayırt edebilir ve manşet oranlar kirlenmez.

7. Veri modeli — SQLite tek dosya

Kurulum yok, tekrar üretilebilir: `git clone` ve tek komut. Vektör veritabanı epizodik hafıza için ayrıdır (§8).



8. Epizodik hafıza

Aranan şey epizot kayıtlarıdır (metin), video parçaları değil. Her kayıt zaten görü kademesinin betimlemesini, tespitleri ve sinyalleri taşır — damıtılmış bir çok-kipli temsil. Video kodlayıcıya API erişimimiz yok ve **öyle bir şey iddia edilmiyor**.

"bu araçla daha önce bir olay olmuş muydu?"

▼ gw.embed() · bge-m3-embed, 1024 boyut

sorgu vektörü

▼ kosinüs

Qdrant – takım başına izole örnek
ön ek: team37 · koleksiyon: episodes
(anahtar yoksa süreç içi örneğe düşer
ve `memory\_backend()` "local" der)

evren-vektor.ssyz.org.tr
port 443 ZORUNLU, yalnız REST
(ön ek üzerinden gRPC yönlenmez)

▼ top-k

geçmiş epizotlar → Nöbetçi cevabı → ****açık olaya kendiliğinden döner****

Yeniden sıralayıcı (`rerank`) **bilerek çağırılmıyor**: organizasyonun kendi ölçümünde R@1 0,95'ten 0,55'e düşüyor. Alias `config.py` 'da yalnız bütünlük için duruyor.

9. Çıktı sözleşmesi

Şartname §5'in dört anahtarı **sözleşmedir**. Genişletilmiş katmanların tamamı bir `try` içindedir; çıktığında dört anahtar yine üretilir.

```
{
  "summary": "B-Hattı sevkiyat alanında istif aracı devrilmesi ve yaralanma riski gözlenmiştir.",
  "events": [
    {"time": "00:15", "event": "İstif aracı devrildi"},
    {"time": "00:20", "event": "Yerde hareketsiz kişi"}
  ],
  "risk": "Yüksek",
  "actions": ["Sağlık ekibini çağır", "Alanı güvenlik altına al"],

  "detail": {
    "episodes": [ ... fazlarıyla epizotlar ... ],
    "risk_assessments": [ ... seviye, gerekçe, önlenebilirlik ... ],
    "handoff_chain": [ ... devir defteri ... ],
    "action_ledger": [ ... çağrılan araçlar, onaylar ... ],
    "root_cause_report": { ... kök neden raporu ... }
  }
}
```


Üç kural:

- **detail fazlalıktır, yerine geçen şey değildir.** Şema: `gozcu/models.py::PipelineOutput`.
- **Bozulmuş koşuda detail null olur.** Dolu bir `detail` "o katmanlar gerçekten koştu" demektir; çöken bir koşuda bu iddia edilmez.
- **actions[] uydurulmuş cümleler değildir.** Liste, Risk Analisti'nin gerçekten bir araca bağladığı aday aksiyonlardan üretilir; insan okunur liste ile makine defteri birbirinden ayrılamaz.

Risk seviyeleri Türkçe kalır: `"Düşük" | "Orta" | "Yüksek" | "Kritik"`.

10. Hata ve kesinti mimarisi

Şartname bunu iki ayrı kaleminden puanlıyor: Mimari ("hata işleme") ve Otonomi ("beklenmedik durumlara karşı tepki"). Demoda gateway **bilerek kesilir** (`POST /api/run/{id}/gateway/cut`).




Aynı felsefe her katmanda tekrarlanır:

Arıza	Davranış
Gateway yanıt vermiyor	3 deneme; metin kademelerinde 90 sn, görü kademesinde 1800 sn zaman aşımı (ayrı — ölçülen bir asılma koşuyu dondurmıştu)
Yorumlayıcı <code>None</code> döndü	Kesinti ise ertelenir; bozuk JSON / kesilemeyen klip ise ertelenmez (yoksa her telafide yeniden sorulur ve hiç kurtulmaz)
Qdrant anahtarı yok	Süreç içi örneğe düşer, patlamaz; <code>memory_backend()</code> bunu <code>"local"</code> diye söyler
Genişletilmiş katman çöktü	Dört anahtar yine döner, <code>detail=null</code>
Denetim "uygunsuz" dedi	Yalnız not düşer — teslim hiçbir koşulda engellenmez
Algı katmanı hiç görmedi	"Kayda değer olay tespit edilmedi" denmez ; körlük ayrı bir cümleyle bildirilir (<code>PerceptionHealth.blind_summary</code>)

Son satır bir dürüstlük kuralıdır: "baktım, bir şey yoktu" ile "hiçbir şey göremedim" aynı cümleyle anlatılamaz.

11. Operatör konsolu

`app.py` üç satırdır; ekran `gozcu/ui/server.py` 'dedir.



Üç tasarım kararı:

- **SSE her zaman tam durum taşır.** Kısmi güncelleme yok; yeniden bağlanma bedavaya çözülür. (Gradio'nun 13 yuvalı protokolü eksik bir çıktıyı hata vermeden yutuyor ve jüriye bayat veri gösteriyordu — 27 Ağustos'ta bu yüzden emekliye ayrıldı.)
- **Harici ağ bağımlılığı sıfır.** CDN yok, font yok, analitik yok, ön yüz framework'ü yok — `gozcu/ui/web/` altındaki her şey depodan servis edilir. Final ağsız bir salonda.
- **Duraklama gerçektir.** `on_event` olayın tam anında, boru hattı iş parçacığında çağrılır ve orada bloklar. "Devam et" düğmesi bir animasyonu değil, generator'ın kendisini sürdürür.

12. Yerellik ve bağımsızlık

Şartname "offline ve yerel ortamda çalışmalı, dış API veya kapalı servis bağımlılığı olmamalı, vLLM benzeri yerel model servisleme kullanılmalı" diyor. Karşılığı:

Bileşen	Nerede koşuyor
Algı katmanının tamamı (ffmpeg, YOLOE, ByteTrack, sinyaller, triyaj)	Bizim makinemizde , ağa hiç çıkmadan
Depo (SQLite)	Bizim makinemizde , tek dosya
Arayüz (FastAPI + statik dosyalar)	Bizim makinemizde , harici kaynak yok
LLM/VLM/gömme	Organizasyonun EVREN servisinde — 8 × NVIDIA H200 üzerinde vLLM , BF16, kuantizasyon yok
Vektör veritabanı	EVREN'in takım başına izole Qdrant örneği

EVREN, şartnamenin yerellik koşulunun **organizasyon tarafından sağlanmış hâlidir**: modeller yarışmanın kendi altyapısında, OpenAI uyumlu bir API'nin arkasında. Ticari hiçbir kapalı servis (OpenAI, Anthropic, Google...) kullanılmıyor; kod tabanında böyle bir istemci yok. Tek bağımlılık `openai` Python **istemci kütüphanesidir** ve yalnızca OpenAI-uyumlu protokolü konuştuğu için seçilmiştir — `base_url` yapılandırılabilir, kendi vLLM'imize yönlendirildiğinde değişen tek şey `config.py` 'daki bir satırdır.

13. Kod haritası

Dosya	Sorumluluk
app.py	Üç satır: konsolu açar
gozcu/config.py	Tek gerçek kaynak: model kimlikleri, eşikler, adresler
gozcu/frames.py · detect.py · track.py · signals.py · adapter.py	Algı katmanı (yerel)
gozcu/motion.py	Kare farkı enerjisi — görü bütçesinin nişancısı
gozcu/loop.py	Karar döngüsü — pencereler, taban, bütçe, generator
gozcu/gateway.py	Kademeli model istemcisi, yeniden deneme, bozulma bayrağı
gozcu/agents/router.py	Yönlendirici — dikkat mekanizması
gozcu/agents/interpreter.py	Yorumlayıcı — klip → ciddiyet + anlar
gozcu/agents/synthesizer.py	Sentezleyici — pencereler → Epizot
gozcu/agents/risk.py	Risk analisti — yalnız okur, aday aksiyonları araca bağlar
gozcu/agents/supervisor.py	Nöbetçi — operatörün konuştuğu ajan
gozcu/agents/reporter.py	Raportör — kök neden raporu
gozcu/guard.py	Denetim — engellemez, not düşer
gozcu/tools/field_systems.py · registry.py	Yedi mock saha sistemi ve tek meşru kapısı
gozcu/fixtures/	Tesis dünyası: personel, ekipman, bakım geçmişi, arşiv
gozcu/memory.py	Epizodik hafıza (Qdrant)
gozcu/store.py · models.py	Depo ve paylaşılan sözleşme
gozcu/report.py	Dört anahtarın derlendiği yer
gozcu/ui/	Konsol (FastAPI + SSE + statik ön yüz)
benchmark/ · bench/	Ölçüm kodu ve çıktıları
tests/	pytest — her ajan sınırı ve demo senaryosu

14. Ölçülmüş rakamlar

Yalnız gerçekten ölçülenler. Kaynağı olmayan sayı bu belgede yer almaz.

Algı katmanı — `bench/perception.md`, elle etiketlenmiş 347 kare:

Ölçüm	Değer
Varlık duyarlılığı	%99
Sayım duyarlılığı	%93
Sıfır tespit oranı	%2
Gerçek zaman katsayısı	0,35 (1,0 altı = canlı akışa yetiştir)
Ortalama mutlak sapma	2,3 kişi/kare

Gecikmeler — 26 Ağustos canlı koşu (`gozcu/config.py` kaydı): `router` 0,3–1,8 sn · `fast` 0,9–1,3 sn · `main` 0,8–2,6 sn · `guard` 0,1 sn · `v1m` 7,0–8,7 sn.

Triyaj maliyeti: 1,9 ms/kare — tek bir görü çağrısının (3.493 ms) **%1,3'ü**.

⚠ Uçtan uca KPI koşusu henüz tamamlanmadı. `bench/kpi.json` bugün `status: "degraded"` okuyor: beş klipten dördü `unmeasured`, biri kısmî. Karar dağılımı, kritik olay yakalama oranı ve zaman damgası sapması **ölçülmedi** — bu belgede o sayılar bilerek boş bırakıldı ve sunuma da tahmin edilmiş bir yüzde konmayacak. Bölüm ⑦ bu koşu tamamlandığında yazılacak.

15. Bilinen sınırlar

Bunları yazmak, saklamaktan daha çok puan getirir — şartname açıklanabilirliği doğrudan puanlıyor.

- **Nesne tanıyıcıda yangın/duman sınıfı yok.** YOLOE açık sözlüklü çalışıyor ama yangının ne sınıfı, ne izi, ne hızı var — yalnız görünür. Bu yüzden yangın klipleri ancak zorunlu görü örneklemesiyle yakalanabiliyor.
 - **Görü kademesinin betimlemeleri genel geçer olabiliyor.** Fabrikaya özel ince ayırım (bir yükün düşmesi ile aracın devrilmesi) her zaman ayırt edilemiyor — demo senaryosundaki operatör düzeltmesi tam da bu yüzden gerçekçi bir düzeltmedir.
 - **Canlı kamera / RTSP kapsam dışı.** `FrameSource` soyutlaması duruyor ve canlı bir kaynak aynı arayüze takılabilir, ama **test edilmiş bir canlı mod yoktur ve iddia edilmiyor.**
 - **Top-K görü bütçesi canlı yayına genelleşmiyor** (§4c).
 - **Hafıza epizot metnini gömüyor**, ham video parçasını değil (§8).
 - **Ses/konuşma analizi yok.** Bas-konuş (STT) yalnız operatörün *girdisi* için, opsiyonel bir ekstra.
 - `events[]` **olaydan önceki pencereleri taşımaz.** Bu kasıtlı: ölçülen bir arızada epizot, park hâlindeki bir kamyonun yanından geçen biri yüzünden 00:00'da açılmış ve kazanın gerçekleştiği 40–50. saniyeyi yutmuştu.
-

16. Şartname eşleştirmesi

Şartname beklentisi (§4)	Mimarideki karşılığı
Çoklu ortam anlama, sahne bütünlüğü	Epizot: pencereler kaynaşarak başlangıç/gelişim/sonuç fazlarına dönüşüyor (§4, §7)
Olay tespiti ve anlamsal yorumlama	Algı (düşük seviye) → Yorumlayıcı → Sentezleyici → Risk Analisti köprüsü (§3)
Zamansal farkındalık	Epizot fazları + <code>events[]</code> zaman damgaları + döngünün videonun saatinde ilerlemesi (§4)
Türkçe üretim ve özetleme	Bütün operatör metinleri Türkçe; risk seviyeleri Türkçe enum (§9)
Aksiyon önerisi ve karar desteği	Aday aksiyonlar araca bağlı ; araçlar video ortasında çağrılıyor (§5)
Yapılandırılmış ve açıklanabilir çıktı	Dört anahtar + <code>detail</code> ; devir defteri ekranda okunuyor (§6, §9)
Yerel çalışma ve bağımsızlık	§12
Model servisleme (vLLM)	EVREN'de vLLM; kademeli yönlendirme kaynak optimizasyonu (§3, §12)
Performans ve ölçeklenebilirlik	Pencere başına ≤ 1 görüş çağrısı; yerel triyaj çağrının %1,3'ü (§4)
Ölçümleme ve KPI	<code>benchmark/</code> + <code>bench/</code> — kısmî, §14'te dürüstçe işaretli
Minimum statik yapı	Taban <i>ne zaman soracağını</i> belirler; <i>neyin önemli olduğuna</i> model karar verir (§4a)
Açık kaynak ve şeffaflık	Apache 2.0, tekrar üretilebilir kurulum, açık fiktür veri kümesi

Kaynaklar

- Plan-of-record: [tasarım spec'i](#)
- Yarışma kuralları: [sartname.md](#)
- Kararların gerekçesi: [decision-log.md](#)
- Teknoloji yığını: [tech-stack.md](#)
- EVREN saha notları: [evren-gateway.md](#)